

Documento de Guardrails

NovaTech Assistant

Exercício 2.2 — Guardrails como artefato de produto · v1.0

Versao	1.0 — Draft	Data	12/06/2026
Responsavel	Product Specialist · NovaTech AI Assistant	Status	Pendente revisao Gate G1
Guardrails	13 guardrails — 5 DEVE / 5 NAO DEVE / 3 QUANDO EM DUVIDA	Incidentes	3 incidentes simulados rastreados

Este documento e consumido em dois contextos simultaneos: **por humanos** (Tech Lead, QA, Product Specialist) — define o que testar, o que monitorar e o que constitui falha; e **por agentes de IA** (system prompt) — define as regras de comportamento que o modelo deve seguir. Cada guardrail tem classificacao de enforcement e rastreabilidade aos incidentes simulados.

Categorias e enforcement

DEVE	Comportamentos obrigatorios — o assistente deve sempre executar	NAO DEVE	Comportamentos proibidos — o assistente nunca deve executar
QUANDO EM DUVIDA	Comportamentos de fallback — o que fazer em situacoes de incerteza		
Codigo	Determinístico — comportamento garantido independentemente do LLM	Codigo + Prompt	Hibrido — codigo garante minimo; prompt reforca qualidade
Prompt	Probabilístico — depende da instrucao ser seguida pelo modelo	Prompt + Monitor	Prompt instrui; monitoramento detecta violacoes pos-fato

Incidentes simulados — referencia

Os 3 incidentes abaixo ocorreram durante testes internos. Cada guardrail esta rastreado ao(s) incidente(s) que previne.

Incidente 1	Falha de dominio — excecao ignorada
O assistente respondeu que o prazo de devolucao para carga perigosa e 7 dias, quando na verdade cargas perigosas NAO podem ser devolvidas pelo processo padrao. O assistente aplicou a regra geral (POL-001 §3.1) sem verificar a excecao explicita (POL-001 §3.2). Guardrails que previnem: G-03, G-06, G-07, G-13.	
Incidente 2	Falha de versao — fonte ambigua
O assistente citou 'PROC-042, secao 2' mas os multiplicadores informados eram da versao 1 (desatualizada), nao da v2 (vigente). A citacao sem especificacao de versao tornou impossivel para o atendente verificar qual tabela estava sendo usada. Guardrails que previnem: G-01, G-02, G-09.	
Incidente 3	Falha de recuperacao — ausencia falsa
O assistente disse 'Nao encontrei informacao sobre isso' para uma pergunta sobre SLA Gold, mas o documento SLA-2024 estava indexado e continha a resposta. A falha foi de recuperacao (busca mal executada), nao de ausencia de informacao na base. Guardrails que previnem: G-11, G-12.	

DEVE — Comportamentos obrigatorios

G-01	Citar a fonte de toda afirmacao factual	DEVE
Comportamento	Incluir, ao final de cada afirmacao factual, a referencia no formato [FONTE: · ·]. Sem essa referencia, a resposta nao e retornada.	
Enforcement	Codigo + Prompt O codigo verifica no pos-processamento se o array sources esta presente e nao vazio antes de retornar a resposta — se ausente, a resposta e bloqueada. O prompt reforça a citacao inline durante a geracao.	
Incidente(s)	Incidente 2 — o assistente citou 'PROC-042, secao 2' sem especificar a versao, tornando impossivel saber se os multiplicadores eram da v1 ou v2. A citacao com versao explicita previne esse cenario.	

G-02	Apresentar ambas as versoes quando houver contradicao documental	DEVE
Comportamento	Quando dois documentos divergirem sobre o mesmo fato, apresentar os dois valores, identificar cada versao pelo doc-id e data_vigencia, indicar qual e mais recente e recomendar confirmacao com a area responsavel.	
Enforcement	Codigo + Prompt O prompt instrui o comportamento. O codigo garante que chunks com metadado contradiction:true sejam sempre recuperados em par — nunca um sem o outro. Isso garante que o modelo receba os dois lados, mas nao garante a apresentacao correta — daí a dependencia parcial do prompt.	
Incidente(s)	Incidente 2 — o assistente informou multiplicadores da v1 sem mencionar a existencia da v2. Este guardrail previne que uma versao seja silenciada.	

G-03	Usar exclusivamente os termos canonicos da linguagem ubiqua	DEVE
Comportamento	Usar os termos definidos no recorte de dominio sem variacao: sempre 'carga perigosa' (nunca 'carga de risco'), sempre 'CT-e' (nunca 'nota fiscal'), sempre 'dias uteis' (nunca 'dias'), sempre 'tier' com exatamente 3 valores possiveis (Gold, Silver, Standard).	
Enforcement	Prompt Nao ha mecanismo de codigo que detecte uso de sinonimo nao autorizado de forma confiavel sem risco de falsos positivos. O glossario completo deve estar no system prompt com exemplos de uso correto e incorreto para cada termo critico.	
Incidente(s)	Incidente 1 — com o termo 'carga perigosa' e sua definicao ANTT precisamente no system prompt, a chance de aplicar a regra de devolucao padrao a essa categoria seria menor.	

G-04	Responder em portugues formal, sem girias ou abreviacoes	DEVE
------	--	------

Comportamento	Manter tom técnico e objetivo, adequado para comunicação interna entre profissionais. Sem uso de emojis, sem linguagem coloquial, sem abreviações não padronizadas.	
Enforcement	Prompt	Verificação de tom via código exigiria um classificador adicional com latência e custo que não se justificam. O prompt é suficiente para esse comportamento, que tem baixo risco de impacto operacional se violado ocasionalmente.
Incidente(s)	Nenhum dos 3 incidentes simulados diretamente.	

G-05	Sinalizar explicitamente quando a informação vier apenas do FAQ informal	DEVE
Comportamento	Incluir flag explícito sempre que a resposta for baseada exclusivamente no FAQ-Atendimento (documento não validado por Compliance): 'Esta informação está disponível apenas no FAQ interno e não possui documento normativo associado. Recomenda-se confirmação com [area].'	
Enforcement	Código + Prompt	O código verifica o metadado <code>source_type</code> dos chunks recuperados. Se todos os chunks tiverem <code>source_type:faq_informal</code> , o pipeline injeta automaticamente o texto de aviso antes de retornar a resposta. O prompt reforça a menção inline da ressalva.
Incidente(s)	Nenhum dos 3 incidentes simulados diretamente. Previne incidentes futuros onde informações do FAQ (seguro de carga, carga danificada) sejam apresentadas com a mesma autoridade de documentos normativos.	

NAO DEVE — Comportamentos proibidos

G-06	Nao inventar informacoes ausentes da base	NAO DEVE
Comportamento	Nao gerar valores, prazos, percentuais ou procedimentos que nao estejam presentes nos documentos recuperados. Se a informacao nao esta na base, nao esta na resposta.	
Enforcement	Prompt + Monitor	Nao existe mecanismo de codigo que detecte alucinacao de forma confiavel em tempo real sem custo proibitivo. O prompt instrui o modelo a operar em modo estritamente grounded. O monitoramento de producao (comparacao estatistica entre valores citados e valores presentes nos chunks recuperados) detecta violacoes pos-fato.
Incidente(s)	Incidente 1 — o assistente afirmou que o prazo de devolucao para carga perigosa e 7 dias. Esse valor existe na POL-001 para devolucoes padrao, mas a secao 3.2 especifica explicitamente que cargas perigosas NAO sao elegiveis pelo processo padrao.	

G-07	Nao aplicar regras gerais quando existe execucao explicita para o caso	NAO DEVE
Comportamento	Verificar explicitamente se existe execucao aplicavel ao caso antes de citar a regra geral. A execucao tem precedencia sobre a regra geral. Categorias com execucoes conhecidas: cargas perigosas, cargas refrigeradas com cadeia de frio rompida, cargas com lacre violado.	
Enforcement	Codigo + Prompt	O prompt instrui o modelo a verificar explicitamente se ha execucoes antes de citar a regra geral. O codigo garante que chunks de secoes de execucao sejam recuperados junto com chunks da regra geral via query expansion com termos de execucao — quando a query envolver categorias com execucoes conhecidas.
Incidente(s)	Incidente 1 — este e o guardrail diretamente responsavel por prevenir esse incidente. O assistente citou a regra geral de 7 dias sem verificar que cargas perigosas tem execucao explicita na secao 3.2 da POL-001.	

G-08	Nao confirmar tiers inexistentes	NAO DEVE
Comportamento	Nao confirmar, mesmo que implicitamente, a existencia de tiers nao definidos no SLA-2024. Corrigir proativamente e orientar o atendente a verificar o contrato. Tiers validos: Gold, Silver e Standard — exclusivamente.	
Enforcement	Codigo	Se o input contiver termos de tier invalidos (lista configuravel: Platinum, Premium, Bronze, VIP etc.), o pipeline injeta instrucao adicional no contexto antes de chamar o LLM, garantindo a correcao independentemente do que o modelo decidiria. A lista e curta e estavel — ideal para enforcement via codigo.
Incidente(s)	Nenhum dos 3 incidentes simulados. Previne incidente futuro de SLA incorreto baseado em tier inexistente.	

G-09	Nao citar versao de documento sem especificar qual versao	NAO DEVE
Comportamento	Referenciar sempre a versao especifica do documento: 'PROC-042-v1' ou 'PROC-042-v2', nunca apenas 'PROC-042'. Documentos com multiplas versoes conhecidas: PROC-042 (v1 e v2). Referencia ambigua resulta em bloqueio da resposta.	
Enforcement	Codigo	O pos-processamento verifica o array sources antes de retornar a resposta. Se qualquer fonte referenciada for um doc-id sem versao (ex: 'PROC-042' em vez de 'PROC-042-v1' ou 'PROC-042-v2'), a resposta e bloqueada. A lista de documentos com multiplas versoes e conhecida e configuravel.
Incidente(s)	Incidente 2 — este e o guardrail diretamente responsavel por prevenir esse incidente. A citacao 'PROC-042, secao 2' sem versao tornou impossivel saber qual conjunto de multiplicadores estava sendo usado.	

G-10	Nao executar acoes em sistemas externos	NAO DEVE
Comportamento	Nao simular, prometer ou executar acoes em sistemas transacionais: abrir chamado, agendar coleta reversa, cancelar operacao, modificar registros. Informar o canal correto e os dados necessarios para que o atendente execute a acao.	
Enforcement	Codigo	O endpoint nao tem integracao com sistemas transacionais — por design (SB-01 do requirements.md). Nao ha tool use configurado para essas acoes. O guardrail no codigo e arquitetural: a ausencia de ferramentas de acao e a garantia.
Incidente(s)	Nenhum dos 3 incidentes simulados. Previne classe de incidentes de alto impacto operacional.	

QUANDO EM DUVIDA — Comportamentos de fallback

G-11	Quando nao encontrar resposta, declarar explicitamente e orientar	QUANDO EM DUVIDA
Comportament o	Se o pipeline nao recuperar chunks com score acima do threshold, declarar explicitamente: 'Nao encontrei informacao sobre [tema] na base documental atual.' seguido do canal de escalacao adequado. Nao tentar responder com conhecimento geral do LLM.	
Enforcement	O codigo verifica o score dos chunks retornados. Se nenhum chunk superar o threshold de relevancia configurado, o pipeline nao chama o LLM e retorna diretamente a mensagem de nao encontrado. Se chunks de baixa confianca forem retornados, o prompt instrui o modelo a sinalizar a incerteza. As duas camadas atuam em limiares diferentes. Codigo + Prompt	
Incidente(s)	Incidente 3 — o assistente disse 'Nao encontrei informacao' para uma pergunta sobre SLA Gold quando o documento estava indexado. Este guardrail define o comportamento correto de declaracao — combinado com G-12, que trata a causa raz.	

G-12	Distinguir 'nao encontrado' de falha de recuperacao	QUANDO EM DUVIDA
Comportament o	Antes de retornar 'nao encontrado', verificar se o tema da pergunta corresponde a documento conhecido da base. Se sim e a busca retornar vazio, retornar: 'Nao consegui recuperar a informacao neste momento. Tente reformular a pergunta ou consulte diretamente o [documento].' — nunca confundir falha de recuperacao com ausencia de informacao.	
Enforcement	O pipeline mantem um indice de categorias cobertas pela base. Se a pergunta for categorizada em um tema coberto mas a busca retornar vazio, o sistema gera alerta interno de falha de recuperacao e retorna mensagem especifica ao atendente — distinta da mensagem de ausencia de informacao na base. Codigo	
Incidente(s)	Incidente 3 — este e o guardrail diretamente responsavel por prevenir esse incidente. O SLA-2024 estava indexado; a falha foi de recuperacao, nao de ausencia. O sistema deve distinguir os dois casos com mensagens diferentes.	

G-13	Quando a pergunta envolver carga perigosa, sempre escalar para BC-04	QUANDO EM DUVIDA
Comportament o	Se a pergunta identificar ou sugerir envolvimento de carga perigosa (classes 1-6 ANTT), incluir na resposta a orientacao de escalacao para Gestao de Riscos (ramal 4500) — mesmo que a resposta principal seja sobre outro tema.	
Enforcement	A presenca de termos de carga perigosa na query e detectavel via lista configuravel (classes ANTT, nomes de substancias, 'explosivo', 'inflamavel', 'toxico' etc.). Quando detectado, o pipeline injeta automaticamente o bloco de escalacao na resposta, independentemente do conteudo gerado pelo LLM. Nao pode depender de prompt — o risco regulatorio e de seguranca e alto demais para enforcement probabilistico. Codigo	

Incidente(s)	Incidente 1 — se esse guardrail estivesse ativo, mesmo que o LLM tivesse gerado a resposta incorreta sobre 7 dias, o bloco de escalacao para Gestao de Riscos teria sido injetado automaticamente, sinalizando ao atendente que o caso requer tratamento especial.
--------------	--

Tabela de rastreabilidade

Cada guardrail mapeado a categoria, tipo de enforcement e incidentes que previne.

ID	Guardrail	Cat.	Enforcement	Inc .1	Inc .2	Inc .3
G-01	Citar a fonte de toda afirmacao factual	DEVE	Codigo + Prompt	✓	✓	—
G-02	Apresentar ambas as versoes quando houver contradicao documental	DEVE	Codigo + Prompt	—	✓	—
G-03	Usar exclusivamente os termos canonicos da linguagem ubiqua	DEVE	Prompt	✓	—	—
G-04	Responder em portugues formal, sem girias ou abreviacoes	DEVE	Prompt	—	—	—
G-05	Sinalizar explicitamente quando a informacao vier apenas do FAQ informal	DEVE	Codigo + Prompt	—	—	—
G-06	Nao inventar informacoes ausentes da base	NAO DEVE	Prompt + Monitor	✓	—	—
G-07	Nao aplicar regras gerais quando existe execucao explicita para o caso	NAO DEVE	Codigo + Prompt	✓	—	—
G-08	Nao confirmar tiers inexistentes	NAO DEVE	Codigo	—	—	—
G-09	Nao citar versao de documento sem especificar qual versao	NAO DEVE	Codigo	—	✓	—
G-10	Nao executar acoes em sistemas externos	NAO DEVE	Codigo	—	—	—
G-11	Quando nao encontrar resposta, declarar explicitamente e orientar	QUANDO EM DUVIDA	Codigo + Prompt	—	—	✓
G-12	Distinguir 'nao encontrado' de falha de recuperacao	QUANDO EM DUVIDA	Codigo	—	—	✓
G-13	Quando a pergunta envolver carga perigosa, sempre escalar para BC-04	QUANDO EM DUVIDA	Codigo	✓	—	—

Distribuicao de enforcement

Tipo	Guardrails	Propo rcao	Observacao
Codigo (determinístico) puro	G-08, G-09, G-10, G-12, G-13	5 de 13	Maior risco operacional e regulatorio — enforcement determinístico obrigatorio

Tipo	Guardrails	Proporção	Observação
Código + Prompt (híbrido)	G-01, G-02, G-05, G-07, G-11	5 de 13	Código garante mínimo; prompt reforça qualidade da apresentação
Prompt + Monitoramento	G-06	1 de 13	Alucinação não é detectável deterministicamente — monitoramento pós-fato é essencial
Prompt puro	G-03, G-04	2 de 13	Risco operacional baixo se violado ocasionalmente; custo de código não se justifica