

# Relatório de Avaliação

Cenário 3 — Fase de Governança e Validação · Exercício 3.1

|            |                                                   |
|------------|---------------------------------------------------|
| Candidato  | Tiago Freire dos Santos                           |
| Papel      | Product Specialist                                |
| Cenário    | 3 — Fase de Governança e Validação                |
| Exercício  | 3.1 — Revisão Crítica das Respostas do Assistente |
| Tópico     | Revisão Crítica de Outputs de IA                  |
| Ferramenta | Claude (chat)                                     |
| Data       | 26/06/2026                                        |
| Avaliador  | Sistema de Avaliação — Trilha AI First / DGS      |

Score do Exercício

3.0 / 3.0

Classificação Final

Aprovado com Distinção

Faixa: 2.5 – 3.0

## Resumo por Dimensão

| Dimensão                       | Score | Nível                  |
|--------------------------------|-------|------------------------|
| D1 — Domínio Conceitual        | 3     | Excelente              |
| D2 — Uso de Ferramentas        | 3     | Excelente              |
| D3 — Qualidade do Entregável   | 3     | Excelente              |
| D4 — Pensamento Crítico        | 3     | Excelente              |
| D5 — Aplicabilidade ao Projeto | 3     | Excelente              |
| MÉDIA FINAL                    | 3.0   | Aprovado com Distinção |

## 1 Resumo da Avaliação

O entregável do exercício 3.1 demonstra alta qualidade em todas as dimensões avaliadas. O candidato realizou análise própria substancial e anterior ao uso da ferramenta, identificou todas as armadilhas obrigatórias com precisão conceitual acima do esperado, e produziu propostas de ajuste concretas e específicas ao contexto NovaTech. A coincidência de 100% com a avaliação do Claude foi documentada honestamente, com reflexão metodológica sobre o que isso revela.

## 2 Scores por Dimensão

### D1 — Domínio Conceitual

3

Demonstra domínio preciso das três categorias de erro (alucinação, fonte não confiável, informação incompleta) e as aplica corretamente — inclusive distinguindo que o caso #4 não é alucinação pura, mas uso indevido de fonte informal. Compreende structured output, HITL e classificação de fonte como mecanismos distintos com propósitos diferentes.

### D2 — Uso de Ferramentas

3

Claude usado como segundo avaliador de forma estruturada e crítica — não como oráculo. O candidato realizou sua análise primeiro, confrontou com o Claude, documentou a concordância e extraiu insight sobre o que ela revela (padrão de falha, não performance do modelo). Evidência clara de geração + revisão crítica.

### D3 — Qualidade do Entregável

3

PDF completo, bem estruturado e acionável. Cobre todos os itens do enunciado: avaliação própria, avaliação do Claude, comparação, classificação de erros e propostas de ajuste. Mapa consolidado de soluções com prioridade (Alta/Crítica) é diferencial concreto. Nenhum campo obrigatório faltando.

### D4 — Pensamento Crítico

3

Ambas as armadilhas obrigatórias identificadas de forma independente e com justificativa precisa. A distinção entre 'não é alucinação pura' (caso #4) e 'fonte não confiável' demonstra refinamento analítico acima do esperado para o nível do exercício. A observação de que nenhum erro foi alucinação pura — e que isso muda o design do harness — é insight de produto genuíno.

### D5 — Aplicabilidade ao Projeto

3

Profundamente ancorado no NovaTech: referencia seções específicas do Anexo A (POL-001 seções 3.1 e 3.2, FAQ itens 32 e 38, SLA-2024 seção 1), cita o ramal 4500 e [sinistros@novatech.com.br](mailto:sinistros@novatech.com.br) como detalhes operacionais omitidos. Propostas conectadas aos guardrails do Cenário 2 (DEVE/NÃO DEVE) e ao conceito de structured output do Cenário 3.

### 3 Verificação de Armadilhas Obrigatórias

Este exercício contém 2 armadilhas obrigatórias definidas na skill de avaliação do papel. A não identificação de qualquer delas implica  $D4 \leq 1$  ou  $D4 \leq 2$  conforme o critério. Resultado:

| Armadilha                                                                                                                                                            | Critério                                          | Identificada? | Qualidade                                                                                                                                                       |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------|---------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Resposta #4</b> — Política de carga danificada<br>Não existe documento formal na base. É alucinação/uso indevido de fonte informal com confiança Alta.            | <b><math>D4 \leq 1</math> se não identificada</b> | ✓ SIM         | Identificada com nuance acima do gabarito mínimo: o candidato precisou que 'não é alucinação pura — tem base no FAQ', classificação tecnicamente mais rigorosa. |
| <b>Resposta #6</b> — Carga perigosa com frete expresso<br>Fonte é o FAQ informal (não validado). Informação sobre carga perigosa deveria vir de documento normativo. | <b><math>D4 \leq 2</math> se não identificada</b> | ✓ SIM         | Identificada como 'caso de maior risco do conjunto' com justificativa correta: gap documental explícito no Anexo A, tema regulatório, confiança Alta indevida.  |

Resultado das Armadilhas

2 / 2 identificadas — D4 sem penalidade

## 4 Pontos Fortes e Pontos de Melhoria

### Pontos Fortes

- Distinção conceitual precisa entre tipos de erro — a análise vai além do óbvio ao identificar que os erros do conjunto são de qualidade documental e processo, não de capacidade do modelo. Isso orienta diretamente o design do harness.
- Propostas de ajuste específicas e graduadas — cada problema tem ação concreta distinta (campo obrigatório no schema, classificação de fonte na ingestão, HITL por tema, confiança máxima por tipo de fonte). Nenhuma proposta genérica do tipo 'melhorar o modelo'.
- Uso honesto e reflexivo da IA — documentar a coincidência de 100% e extrair dela insight sobre consistência da análise (em vez de apenas declarar 'concordamos') demonstra maturidade metodológica acima do esperado para o nível do exercício.

### Pontos de Melhoria

- O caso #4 merece classificação mais assertiva frente ao gabarito. A skill de avaliação registra #4 como 'alucinação' — o candidato classificou como 'fonte não confiável + informação incompleta'. A distinção é defensável e tecnicamente mais precisa, mas numa certificação formal convém registrar explicitamente a divergência do termo do enunciado, para evitar ambiguidade na avaliação por terceiros.
- As propostas de ajuste poderiam referenciar explicitamente os guardrails do Cenário 2. A conexão está implícita (usa a linguagem DEVE/NÃO DEVE), mas citar formalmente 'Guardrail G-07 do Cenário 2' tornaria o documento mais rastreável e evidenciaria a continuidade entre cenários — critério de D5.
- A comparação entre avaliação própria e avaliação do Claude poderia ser mais explícita. O entregável afirma que coincidiram em 100%, mas não registra o processo de confronto — o que foi verificado primeiro, o que o Claude acrescentou ou confirmou. Tornar esse processo visível fortalece a evidência de D4 para um avaliador externo.

## 5 Classificação Final e Próximos Passos

| Nota      | Classificação          | Status      |
|-----------|------------------------|-------------|
| 2.5 – 3.0 | Aprovado com Distinção | ■ CANDIDATO |
| 2.0 – 2.4 | Aprovado               | —           |
| 1.5 – 1.9 | Aprovado com Ressalvas | —           |
| < 1.5     | Não Aprovado — Refazer | —           |

### Próximos Passos

|                      |                                                                                                                                                                    |
|----------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Tópicos para Reforço | Nenhum. Score máximo em todas as dimensões. O candidato está apto a avançar.                                                                                       |
| Próximo Exercício    | Exercício 3.2 — Harness de Produto para Melhoria Contínua (Cenário 3)                                                                                              |
| Observação           | A performance no Ex. 3.1 é referência de nível para o Cenário 3. Recomenda-se manter o mesmo rigor de análise própria antes do uso da IA nos exercícios seguintes. |

Avaliação gerada em 26/06/2026 — Trilha de Certificação AI First | DGS / DB1 Global Software — Documento confidencial