

Relatório de Avaliação

Cenário 3 — Fase de Governança e Validação · Exercício 3.2

Candidato	Tiago Freire dos Santos
Papel	Product Specialist
Cenário	3 — Fase de Governança e Validação
Exercício	3.2 — Harness de Produto para Melhoria Contínua
Tópico	Harness Engineering
Ferramenta	Claude (chat)
Data	26/06/2026
Avaliador	Sistema de Avaliação — Trilha AI First / DGS

Score do Exercício

3.0 / 3.0

Classificação Final

Aprovado com Distinção

Faixa: 2.5 – 3.0

Resumo por Dimensão

Dimensão	Score	Nível
D1 — Domínio Conceitual	3	Excelente
D2 — Uso de Ferramentas	3	Excelente
D3 — Qualidade do Entregável	3	Excelente
D4 — Pensamento Crítico	3	Excelente
D5 — Aplicabilidade ao Projeto	3	Excelente
MÉDIA FINAL	3.0	Aprovado com Distinção

1 Resumo da Avaliação

Entregável de excelência técnica e conceitual que excede os critérios mínimos do exercício em todas as dimensões. O candidato produziu um harness de produto completo, estruturado e profundamente ancorado no contexto NovaTech, com processo de feedback em 6 etapas rastreáveis, regression testing em 3 camadas com critérios objetivos de aprovação, e HITL com 8 gatilhos nomeados, aprovadores definidos e prazos concretos. O documento é acionável imediatamente — não requer interpretação adicional para ser operacionalizado.

2 Scores por Dimensão

D1 — Domínio Conceitual

3

Demonstra compreensão precisa e aplicada de harness engineering: distingue enforcement via prompt (probabilístico) de enforcement via código (determinístico), explica por que HITL não pode ser aplicado a tudo (gargalo), e fundamenta cada decisão de design com princípio explícito. O schema de captura de feedback com campo motivo tipado (enum com categorias específicas) evidencia domínio de structured outputs aplicado ao próprio processo de governança.

D2 — Uso de Ferramentas

3

Claude usado como parceiro de design, não como gerador passivo. Evidência: o documento integra os resultados do Ex. 3.1 (os 5 casos do Golden Set derivam diretamente dos erros identificados na avaliação anterior), o que demonstra uso iterativo e acumulativo da ferramenta ao longo do cenário. O output foi criticamente refinado — a distinção entre mudanças que exigem e que não exigem HITL revela curadoria ativa, não aceitação irrestrita.

D3 — Qualidade do Entregável

3

Documento completo, correto, específico e acionável. Cobre os 3 pilares obrigatórios com profundidade além do mínimo: feedback com schema tipado e 4 ações de triagem com responsável e critério; regression testing com 3 camadas e critérios numéricos (100%, 0 violações, 95%); HITL com 8 gatilhos, aprovador nomeado por perfil, prazo máximo e lista explícita do que não exige aprovação. Nenhum campo vago ou genérico.

D4 — Pensamento Crítico

3

Dois pontos de julgamento próprio se destacam acima do esperado: (1) a decisão de listar explicitamente o que NÃO exige HITL — contrapartida necessária para evitar que o harness se torne gargalo burocrático, ponto que o enunciado não exigia e que revela compreensão sistêmica; (2) a 'Regra de Ouro' formulada na Seção 1 sintetiza o princípio de operação do harness de forma que poderia entrar num AGENTS.md sem modificação. Pensamento de produto, não de checklist.

D5 — Aplicabilidade ao Projeto

3

Conexão profunda e rastreável com os cenários anteriores: referencia explicitamente os guardrails do Cenário 2 (DEVE/NÃO DEVE/QUANDO EM DÚVIDA) como invariantes do regression testing; nomeia Azure AI Search, pipeline RAG, PROC-043, ANTT e classes de carga perigosa como contexto concreto; o Golden Set parte dos 6 casos do Ex. 3.1; a matriz de responsabilidades inclui Compliance como co-aprovador para carga perigosa — decisão diretamente derivada do risco identificado na avaliação anterior.

3 Verificação de Critérios Obrigatórios

O Exercício 3.2 não contém armadilhas intencionais — os critérios são positivos (verificação do que deve estar presente). Todos foram verificados e atendidos:

Critério obrigatório	Atendido	Evidência no entregável
Processo de feedback completo: do atendente até a melhoria efetiva (novo doc / ajuste de prompt / reindexação)	✓ Sim	Ciclo F1→F7 com 4 ações de triagem, responsável e critério de decisão para cada. Etapa F7 fecha o ciclo com verificação de resultado.
Regression testing reconhece efeitos colaterais de mudanças em IA	✓ Sim	Princípio explícito na Seção 2: 'alteração de prompt que melhora respostas sobre devolução pode degradar respostas sobre SLA'.
Regression testing verifica que guardrails do Cenário 2 não regridem	✓ Sim	Camada 2 dedicada exclusivamente a guardrails (15 casos mínimos), com bloqueio imediato em qualquer falha — sem exceção.
HITL concreto: define quais mudanças exigem aprovação e quem aprova	✓ Sim	8 gatilhos com aprovador nomeado por perfil (PS, TL, Compliance, Diretoria TI) e prazo máximo por tipo de mudança.
Preserva guardrails do Cenário 2 como invariantes ao longo da evolução	✓ Sim	Guardrails listados como gatilho obrigatório de HITL (Seção 3.1) e como critério de bloqueio na camada 2 do regression testing.

Resultado

5 / 5 critérios atendidos — sem penalidade em nenhuma dimensão

4 Pontos Fortes e Pontos de Melhoria

Pontos Fortes

- O Golden Set é derivado, não inventado. Os 5 casos fixos (GS-01 a GS-05) são extraídos diretamente dos erros identificados no Ex. 3.1, com gabarito e guardrail associado para cada um. Isso fecha o ciclo entre revisão crítica e governança — os erros de hoje viram casos de teste permanentes para o futuro.
- A lista de mudanças que NÃO exigem HITL é tão importante quanto a lista das que exigem. O candidato entendeu que um harness sem essa contrapartida vira burocracia. Cinco categorias de mudança segura explicitadas com critério claro de separação — adição de valor por julgamento próprio, não solicitada pelo enunciado.
- A Seção 4 (Visão Consolidada) é operacionalizável sem interpretação adicional. As 5 Regras Inegociáveis formulam o harness em linguagem que poderia entrar diretamente num AGENTS.md ou num runbook de operação — nível de concretude que distingue um artefato de produto de um documento de conceito.

Pontos de Melhoria

- O schema de captura de feedback (Seção 1.1) poderia incluir campo de 'tema' (ex: devolução, frete especial, SLA, carga perigosa). Isso permitiria triagem automatizada por categoria de risco e alimentaria o regression testing com dados reais de distribuição de perguntas — conexão que o entregável quase fecha, mas não explicita.
- A Seção 2 não define quem executa o regression testing nem com qual ferramenta. A estrutura das 3 camadas é clara, mas o artefato fica incompleto para operacionalização sem saber se é um script automatizado, planilha manual ou chamada à API do assistente. Uma linha de responsável e ferramenta por camada resolveria.
- O ciclo de feedback (F7) poderia ter critério de encerramento mais preciso. 'Feedbacks do mesmo tipo cessaram' é o critério, mas não define horizonte de tempo nem limiar de aceitação (zero feedbacks? menos de X por semana?). Para um Product Specialist, definir o critério de sucesso com precisão é parte do entregável.

5 Classificação Final e Próximos Passos

Nota	Classificação	Status
2.5 – 3.0	Aprovado com Distinção	■ CANDIDATO
2.0 – 2.4	Aprovado	—
1.5 – 1.9	Aprovado com Ressalvas	—
< 1.5	Não Aprovado — Refazer	—

Próximos Passos

Tópicos para Reforço	Nenhum. Score máximo em todas as dimensões. Candidato conclui o Cenário 3 com performance consistente nos dois exercícios.
Status no Cenário 3	Ex. 3.1: 3.0 · Ex. 3.2: 3.0 · Média do Cenário: 3.0 — Aprovado com Distinção
Observação	O nível de maturidade demonstrado nos dois exercícios — especialmente a capacidade de derivar artefatos operacionais a partir de análise crítica anterior e de conectar decisões entre cenários — é referência de excelência para a Trilha.

Avaliação gerada em 26/06/2026 — Trilha de Certificação AI First | DGS / DB1 Global Software — Documento confidencial